

GEN İFADE VERİSİYLE KANSER RİSKİ TESPİTİ

Makine Öğrenmesi Projesi

Alan	Bilgi
Ders	Veri Madenciliği — 2025-2026 Bahar
Proje Türü	Dönem İçi Proje
Öğrenci	Furkan Gül
Öğrenci No	2311505269
Tarih	05.06.2026

1. Giriş ve Motivasyon

1.1 Problemin Tanımı

Kanser, dünya genelinde en fazla ölüme yol açan hastalıklardan biridir. Gen ifadesi (gene expression) verileri, hücrelerin hangi genleri ne kadar aktif kullandığını gösterir. Bu veriler, tümörlü ve sağlıklı dokuları birbirinden ayırt etmek için kullanılabilir.

Bu projede iki adet gen ifadesi değişkeni (Gen1 ve Gen2) kullanılarak bireyin kanser riskini tahmin eden makine öğrenmesi modelleri geliştirilmiştir. Hedef değişken ikili sınıflandırmaya dayanmaktadır: 0 = Sağlıklı, 1 = Kanser.

1.2 Projenin Amacı

- gen_expression.csv veri seti üzerinde ikili sınıflandırma gerçekleştirmek
- KNN, Karar Ağaçları, Naive Bayes ve K-Means algoritmalarını uygulamak
- Bias-Varyans dengesi, aşırı öğrenme ve K-Fold kavramlarını incelemek
- ROC-AUC, Karmaşıklık Matrisi ve Jaccard İndeksi ile modelleri karşılaştırmak

2. Veri Seti ve Keşifsel Veri Analizi (EDA)

2.1 Veri Seti Hakkında

Kullanılan veri seti gen_expression.csv dosyasından okunmaktadır. Üç sütundan oluşmaktadır:

Sütun	Açıklama	Tip
Gen1	Birinci gen ifadesi değeri	Sayısal
Gen2	İkinci gen ifadesi değeri	Sayısal
Kanser	0 = Sağlıklı, 1 = Kanser (Hedef)	İkili

2.2 Temel Gözlemler

Keşifsel veri analizi kapsamında sınıf dağılımı, eksik değer kontrolü ve gen dağılımları incelenmiştir. Veri setinde eksik değer bulunmamaktadır. Sınıf dağılımı dengeli olup Sağlıklı ve Kanser sınıfları yaklaşık eşit temsil edilmektedir (%50 - %50). Gen1 ile Gen2 değerlerinin kanserli ve sağlıklı bireyler arasında belirgin farklılık gösterdiği scatter plot analizinde gözlemlenmiştir.

3. Veri Ön İşleme

3.1 Eğitim / Test Bölmesi

Veri seti %80 eğitim, %20 test olarak ayrılmıştır. Stratified split kullanılarak her iki kümede de sınıf oranı korunmuştur.

3.2 Normalizasyon

Mesafeye dayalı algoritmalar (KNN, K-Means) farklı ölçeklerdeki değişkenlere karşı hassastır. Bu nedenle StandardScaler (Z-score normalizasyonu) uygulanmıştır. Scaler yalnızca eğitim seti üzerinde fit edilmiş; test setine yalnızca transform uygulanmıştır. Bu yaklaşım veri sızıntısını (data leakage) önler.

4. Temel Kavramlar

4.1 Aşırı Öğrenme ve Öğrenememe

Overfitting (Aşırı Öğrenme): Model eğitim verisini ezberler, test verisinde başarısız olur. Yüksek eğitim doğruluğu ile düşük test doğruluğu gözlemlenir. Çok derin karar ağaçları bu durumun tipik örneğidir.

Underfitting (Öğrenememe): Model yeterince karmaşık değildir; hem eğitim hem de test verisinde düşük başarı gösterir. Çok basit modeller bu duruma düşer.

4.2 Bias-Varyans Dengesi

Yüksek bias underfitting'e, yüksek varyans ise overfitting'e işaret eder. İdeal model bu iki uç arasında denge kurar. Projede karar ağacı derinliği artırıldıkça eğitim doğruluğunun yükseldiği, test doğruluğunun belirli bir noktadan sonra düştüğü gözlemlenmiştir.

4.3 K-Fold Cross Validation

Veriyi tek seferinde bölmek yerine K parçaya bölerek her parçayı sırayla test seti olarak kullanma yöntemidir. Bu proje kapsamında K=5 ve K=10 denenmiştir. K-Fold, tek bir train/test bölmesine kıyasla daha güvenilir performans tahmini sunar.

5. Model Eğitimi

Dört farklı algoritma uygulanmıştır:

Model	Tür	Temel Fikir
KNN	Mesafeye dayalı	En yakın K komşunun çoğunluk sınıfını atar
Karar Ağacı	Kural tabanlı	If-else kuralları ağacı oluşturur (max_depth=5)
Naive Bayes	Olasılıksal	Bayes teoremi + özellikler bağımsız varsayımı
K-Means	Kümeleme (gözetimsiz)	Etiket kullanmaz, veriyi doğal kümelere ayırır

Not: K-Means denetlenmemiş bir öğrenme algoritmasıdır. Sınıflandırma için doğrudan kullanılmaz; küme etiketleri gerçek etiketlerle eşleştirilerek değerlendirme yapılır.

6. Model Değerlendirme

6.1 Karmaşıklık Matrisi

Her model için karmaşıklık matrisi oluşturulmuştur. Dört temel metrik şu şekilde tanımlanır:

- TP (True Positive): Gerçekte kanser, doğru tahmin edilmiş
- TN (True Negative): Gerçekte sağlıklı, doğru tahmin edilmiş
- FP (False Positive): Gerçekte sağlıklı, yanlışlıkla kanser dendi — Tip I Hata
- FN (False Negative): Gerçekte kanser, yanlışlıkla sağlıklı dendi — Tip II Hata, tıbbi açıdan en tehlikeli

6.2 Performans Ölçütleri

Metrik	Formül	Ne Ölçer?
Accuracy	$(TP+TN) / (TP+TN+FP+FN)$	Genel doğruluk oranı
Precision	$TP / (TP+FP)$	Kanser dediğinde ne kadar doğru?
Recall	$TP / (TP+FN)$	Kanserlerin kaçını yakaladı?
F1-Score	$2 \times (P \times R) / (P+R)$	Precision ve Recall dengesi
Jaccard	$TP / (TP+FP+FN)$	Küme örtüşme benzerliği (0–1)

6.3 ROC Eğrisi ve AUC

ROC eğrisi, sınıflandırma eşiği değiştikçe True Positive Rate ile False Positive Rate'in nasıl değiştiğini gösterir. AUC (Area Under Curve) bu eğrinin altındaki alanı ifade eder; 1.0 mükemmel sınıflandırıcıyı, 0.5 ise rastgele tahmin düzeyini temsil eder. K-Means olasılık çıktısı üretmediğinden ROC hesabı dışında tutulmuştur.

7. Dengesiz Sınıflar

Gerçek dünya tıbbi veri setlerinde kanser vakaları genellikle sağlıklı bireylere kıyasla çok daha az sayıda bulunur. Bu durumda Accuracy metriği yanıltıcı olabilir; model her örneği çoğunluk sınıfına atayarak yüksek Accuracy elde edebilir.

Projede yapay dengesizlik oluşturularak bu durum simüle edilmiştir (orijinal veri dengeli; %50-%50). Dengeli ve dengesiz durumda KNN karşılaştırılmış; dengesiz veride Accuracy yüksek kalırken F1-Score'un belirgin şekilde düştüğü gözlemlenmiştir.

Başlıca çözüm yöntemleri:

- Oversampling (SMOTE): Azınlık sınıfından yapay örnekler üretir
- Undersampling: Çoğunluk sınıfından örnek siler
- `class_weight='balanced'`: Model içi ağırlıklandırma

8. Sonuç ve Karşılaştırma

8.1 Model Karşılaştırma Tablosu

Dört algoritmanın test seti üzerindeki performansı aşağıdaki gibi özetlenebilir (gerçek değerler notebook çalıştırıldığında elde edilir):

Model	Accuracy	F1-Score	Jaccard	AUC
KNN (k=5)	Notebook çıktısı	Notebook çıktısı	Notebook çıktısı	Notebook çıktısı
Karar Ağacı (d=5)	Notebook çıktısı	Notebook çıktısı	Notebook çıktısı	Notebook çıktısı
Naive Bayes	Notebook çıktısı	Notebook çıktısı	Notebook çıktısı	Notebook çıktısı
K-Means	Notebook çıktısı	Notebook çıktısı	Notebook çıktısı	—

8.2 Genel Değerlendirme

- KNN: Mesafe tabanlı, basit ve yorumlanabilir. K değeri doğruluğu doğrudan etkiler.
- Karar Ağacı: Görsel olarak yorumlanabilir. Derin yapılarda overfitting riski yüksektir.
- Naive Bayes: Hızlı ve olasılıksal. Özellikler arası bağımsızlık varsayımı her zaman gerçekçi değildir.
- K-Means: Gözetimsiz algoritma olduğundan sınıflandırma metriklerinde dezavantajlıdır.

Bias-Varyans analizi, karar ağacında derin yapıların overfitting yarattığını ortaya koymuştur. K-Fold cross validation ile daha güvenilir performans tahminleri elde edilmiştir. Dengesiz sınıf örneğinde Accuracy'nin yanıltıcı olabileceği, F1-Score ve AUC gibi metriklerin daha bilgilendirici olduğu gözlemlenmiştir.

9. Kaynakça

1. Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow. O'Reilly Media.
2. Scikit-learn Documentation. <https://scikit-learn.org/stable/>
3. Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning. Springer.
4. He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. IEEE Transactions on Knowledge and Data Engineering.